



UNIVERSIDAD CENTRAL DE VENEZUELA

FACULTAD DE CIENCIAS ECONÓMICAS Y SOCIALES
ESCUELA DE ESTADÍSTICA Y CIENCIAS ACTUARIALES

ANÁLISIS DE FACTORES DEMOGRÁFICOS Y SU
IMPACTO EN LOS PATRONES DE CONSUMO EN
UNA TIENDA MINORISTA DURANTE EL AÑO 2023.

Trabajo: Informe Académico Computación I

AUTOR:

Johan Infante
Eddie Palomino
Juan Covarrubia

PROFESOR:

Jesus Ochoa
Oliver Triveño

Índice general

Resumen	III
1. Introducción	1
2. Planteamiento del Problema	2
2.1. Justificación	3
2.2. Objetivos	3
2.2.1. Objetivo General	3
2.2.2. Objetivos Específicos	3
2.3. Cobertura	4
2.3.1. Horizontal	4
2.3.2. Vertical	4
2.4. Periodo de Referencia	4
2.5. Variables	4
3. Marco Teórico	6
3.1. Bases Teóricas	6
3.1.1. Definición Retail	6
3.1.2. Análisis Exploratorio de Datos (EDA)	6
3.1.3. Estadística Descriptiva	7
3.1.4. Pirámide Poblacional	7
3.1.5. Matriz de Correlación	7
3.1.6. Análisis de Series de Tiempo Simples	8
3.1.7. Tablas de Contingencia y Gráficos de Barras Apiladas	8
4. Marco Metódico	9
4.1. Bases metódicas utilizadas en el trabajo de investigación	9
4.1.1. Origen y Tratamiento de los Datos	9
4.1.2. Herramientas y Lenguajes de Programación	10
5. Análisis de Resultados	11
5.1. Ventajas y Desventajas de los Tests Aplicados	11
5.1.1. Matriz de Correlación:	11

5.1.2. Discretización Demográfica:	11
5.2. Estadística descriptiva por categoría	12
5.3. Correlación de Variables Numéricas	13
5.4. Evolución Temporal de los Ingresos (Serie de Tiempo Simple)	14
5.5. Preferencias de Categorías por Edad	15
6. Conclusiones y Recomendaciones	16
A. Anexo A	17
B. Anexo B	18
C. Anexo C	19

Resumen

Resumen del trabajo de investigación...

Introducción

Planteamiento del Problema

En la actualidad, el sector minorista (retail) se enfrenta a un entorno altamente competitivo donde la comprensión del cliente es vital. Tal como lo demuestra el Estudio Retail 2024-2025 de la firma de análisis GfK, las dinámicas de consumo y la frecuencia de compra están directamente vinculadas a la segmentación generacional y el perfil del comprador, obligando a las marcas a estudiar sus datos demográficos para anticipar el comportamiento del mercado. Las empresas ya no solo venden productos sino que gestionan información estratégica para optimizar su inventario y fidelizar a sus consumidores.

A partir de esta realidad, surge la necesidad de aplicar este mismo enfoque analítico a nivel micro. Al disponer de un conjunto de datos transaccionales del año 2023 de una tienda *retail*, existe la oportunidad de extraer información valiosa que describa quiénes son los clientes y cómo interactúan con los productos ofrecidos. El problema central radica en transformar estos datos crudos en información estructurada que permita comprender las dinámicas básicas de consumo sin recurrir a modelos predictivos complejos, basándose estrictamente en el comportamiento histórico registrado.

El problema central de esta investigación radica en determinar: ¿Existe una asociación observable entre el perfil demográfico del consumidor y sus hábitos de gasto y elección de productos en el conjunto de datos de 2023?

Debido a esto, se plantea las siguientes preguntas de investigación:

1. ¿Cuál es el perfil demográfico de los clientes que conforman el conjunto de datos de 2023 y cómo se distribuyen gráficamente según su edad y género?
2. ¿Cómo fluctúa el comportamiento de las ventas y el gasto promedio mensual a lo largo del año?
3. ¿Cuáles son las preferencias de compra en las distintas categorías de productos según los diferentes grupos etarios de los consumidores?

2.1. Justificación

La presente investigación se justifica desde un punto de vista práctico y académico. En el ámbito práctico, el análisis descriptivo de bases de datos de clientes permite a cualquier negocio identificar a su público objetivo real y observar hechos concretos, como qué productos tienen mayor salida en ciertos meses o qué rango de edad consume más tecnología frente a artículos de hogar. Esta información es la piedra angular para cualquier toma de decisiones comerciales, diseño de campañas o gestión de inventario. Desde el punto de vista académico, este trabajo representa una aplicación directa y rigurosa de los fundamentos de estadística descriptiva y computación del primer semestre. Permite demostrar el dominio en la limpieza de datos, el uso de tablas de frecuencia, la visualización de datos (como la construcción de pirámides poblacionales) y el análisis de correlación simple. Al limitar el estudio a herramientas descriptivas, se garantiza un manejo profundo y preciso de los resultados obtenidos, sentando las bases analíticas necesarias para futuras investigaciones más complejas.

2.2. Objetivos

2.2.1. Objetivo General

- Analizar el perfil demográfico y el comportamiento de compra de los clientes registrados en el conjunto de datos de retail durante el año 2023, utilizando técnicas de estadística descriptiva para la identificación de patrones de consumo.

2.2.2. Objetivos Específicos

- Describir la estructura demográfica de los consumidores mediante la elaboración de una pirámide poblacional que clasifique a los clientes por edad y género.
- Identificar el grado de asociación lineal entre las variables cuantitativas del estudio como edad, ingresos y monto de gasto a través del cálculo de una matriz de correlación.
- Describir la fluctuación de las ventas a lo largo del año 2023 para identificar los picos de demanda y el comportamiento regular en periodos particulares.
- Determinar las preferencias de compra por categoría de producto según distintos rangos de edad, utilizando tablas de frecuencia cruzada (tablas de contingencia).

2.3. Cobertura

2.3.1. Horizontal

La cobertura horizontal abarca las características intrínsecas de cada cliente y transacción registrada en la base de datos de *retail*. Se consideran las dimensiones demográficas de los consumidores (como edad y género) y las métricas descriptivas de su comportamiento de consumo (categorías de productos y monto de gasto) dentro del mercado estudiado.

2.3.2. Vertical

La cobertura vertical del trabajo de investigación comprende un total de **1,000 observaciones** (registros). Cada fila representa una transacción única realizada por un cliente. El alcance temporal de los datos se circunscribe al año 2023, lo que permite un análisis transversal y descriptivo del comportamiento de ventas en dicho periodo.

Tabla 2.1: Variables consideradas

TIPO	VARIABLE	DESCRIPCIÓN
Catagórica	Género	Identidad de género del cliente registrado
Numérica	Edad	Edad del consumidor expresada en años
Catagórica	Categoría_Producto	Clasificación del artículo adquirido (ej. Tecnología, Hogar, Vestimenta)
Numérica	Gasto_Total	Monto monetario total gastado en la transacción
Fecha/Numérica	Fecha_Compra	Día, mes y año exacto de la transacción durante el periodo 2023

2.4. Periodo de Referencia

Periodo de Referencia “El análisis se basa en datos históricos recolectados durante el año fiscal 2023, permitiendo observar el comportamiento del consumidor a lo largo de los doce meses de dicho periodo.”

2.5. Variables

La variable principal de interés económico en este estudio es el **Gasto_Total** (o *Total_Sales*), que representa el volumen monetario de las transacciones realizadas por los clientes. Como variables descriptivas y de segmentación se analizan:

1. Variables Demográficas: **Edad y Género.**
2. Variables Comerciales: **Categoría_Producto.**

3. Variables Temporales: **Fecha_Compra.**

Marco Teórico

En el presente capítulo se exponen los fundamentos teóricos y metodológicos que sustentan el desarrollo de esta investigación. Dado que el objetivo central del proyecto es comprender la asociación entre los factores demográficos y los patrones de consumo en el sector minorista durante el año 2023, resulta indispensable establecer un marco de referencia claro. A continuación, se definen las herramientas de la estadística descriptiva y las técnicas de visualización de datos empleadas, las cuales permiten transformar los registros transaccionales crudos en información estratégica para la toma de decisiones, garantizando así la validez y el rigor analítico de los resultados obtenidos.

3.1. Bases Teóricas

Para sustentar el análisis del comportamiento de consumo en el sector retail durante el año 2023, la presente investigación se fundamenta en los siguientes conceptos estadísticos y analíticos:

3.1.1. Definición Retail

El término retail, o comercio minorista, hace referencia al sector económico que engloba a las empresas especializadas en la venta masiva de productos o servicios a múltiples clientes finales. Kotler y Keller (2012) lo definen como “todas las actividades que intervienen en la venta de bienes o servicios directamente a los consumidores finales para su uso personal y no comercial”. Este sector se caracteriza por un alto volumen de transacciones y la necesidad constante de analizar los patrones de compra para optimizar el inventario.

3.1.2. Análisis Exploratorio de Datos (EDA)

El Análisis Exploratorio de Datos es un enfoque metodológico inicial en el análisis estadístico que tiene como objetivo resumir las características principales de un conjunto

de datos, frecuentemente utilizando métodos visuales. En el contexto de las ventas minoristas, el EDA permite descubrir patrones de consumo, identificar anomalías y establecer la relación básica entre el perfil demográfico del cliente y su volumen de compra, sin la necesidad de formular modelos predictivos complejos desde el inicio.

3.1.3. Estadística Descriptiva

Es la rama de la estadística encargada de recolectar, analizar y presentar los datos de manera estructurada y comprensible. Para este proyecto, se emplean medidas de tendencia central (como el promedio de edad) y medidas de frecuencia (como el conteo de transacciones totales) para resumir el comportamiento macro de la tienda en 2023.

3.1.4. Pirámide Poblacional

Es una representación gráfica, típicamente estructurada como un histograma bidireccional, que muestra la distribución de una población según grupos de edad y género. En el ámbito del retail, esta herramienta visual permite segmentar el mercado e identificar rápidamente qué segmento demográfico representa la mayor fuerza compradora del negocio, facilitando la toma de decisiones sobre inventario y marketing.




Figura 1, fuente: elaboración propia a partir de referencias web.

3.1.5. Matriz de Correlación

Es una tabla matemática que muestra los coeficientes de correlación entre diferentes variables numéricas. Su función principal es medir el grado de asociación lineal entre dos métricas (por ejemplo, la edad de un cliente y el monto total gastado). Los valores

oscilan entre -1 y 1, donde valores cercanos a 1 indican una fuerte relación positiva, y los cercanos a 0 indican la ausencia de relación. Visualmente, se suele representar mediante un mapa de calor (Heatmap) para facilitar su interpretación.




Figura 2, fuente: elaboración propia a partir de referencias web.

3.1.6. Análisis de Series de Tiempo Simples

Se refiere al estudio de las variaciones o fluctuaciones periódicas en los datos a lo largo de un ciclo temporal específico (en este caso, los doce meses del año). Utilizando gráficos de líneas, se busca identificar picos de demanda y valles de ventas, lo cual es fundamental en el comercio minorista para planificar la reposición de mercancía en temporadas altas.

3.1.7. Tablas de Contingencia y Gráficos de Barras Apiladas

Una tabla de contingencia es una herramienta que tabula la frecuencia de observaciones de múltiples variables categóricas. Gráficamente, esto se traduce en gráficos de barras apiladas, los cuales permiten observar la proporción que ocupa cada subcategoría (por ejemplo, el tipo de producto) dentro de un grupo mayor (los rangos de edad). Esta técnica es ideal para responder interrogantes sobre preferencias de productos específicas por segmento etario.

Marco Metódico

En este capítulo se describen los procedimientos, técnicas y herramientas tecnológicas empleadas para llevar a cabo el Análisis Exploratorio de Datos (EDA) sobre los registros de ventas del sector minorista correspondientes al año 2023. Se detalla el tratamiento aplicado a la base de datos y la justificación de los recursos computacionales utilizados.

4.1. Bases metódicas utilizadas en el trabajo de investigación

4.1.1. Origen y Tratamiento de los Datos

La presente investigación se enmarca en un diseño no experimental de corte transversal (analizando un periodo específico del año 2023). Es de tipo descriptiva y cuantitativa, ya que busca especificar las propiedades y características demográficas de los consumidores mediante el análisis estadístico de sus compras. El conjunto de datos transaccionales fue extraído de un repositorio público validado en la plataforma de ciencia de datos Kaggle. Dicho conjunto fue sometido a procesos de limpieza (Data Wrangling) para asegurar la consistencia de las variables de edad, género, categorías y montos de compra. Destacando las siguientes operaciones metodológicas:

- Transformación temporal: Se convirtió la variable de la fecha de compra a un formato estandarizado de series de tiempo (Datetime) para poder aislar y agrupar los datos según la estacionalidad mensual.
- Discretización de variables (Binning): Para la creación de la pirámide poblacional, se transformó la variable continua $.^{Edad}$ en una variable categórica (Rango Edad). Se agruparon a los clientes en cinco intervalos específicos ($\{25, 26-35, 36-45, 46-55, 56+\}$), lo que permitió cruzar esta información demográfica con las preferencias de categorías de productos.

4.1.2. Herramientas y Lenguajes de Programación

Para la ejecución de este marco metodológico, se seleccionó el lenguaje de programación Python, reconocido por su robustez en la ciencia de datos. El procesamiento se llevó a cabo mediante la integración de las siguientes librerías especializadas:

- Pandas: Utilizada como la estructura principal para la manipulación de datos. Mediante esta librería se ejecutaron las funciones de agrupación poblacional y el cálculo matemático de la matriz de correlación de Pearson/Spearman para evaluar la relación entre la edad y el monto de compra.
- Plotly Express: Herramienta seleccionada para la visualización gráfica de los datos. Su implementación metodológica permitió construir representaciones bidireccionales (para el contraste de géneros) y mapas de calor (Heatmaps), superando las limitaciones de los gráficos estáticos tradicionales.
- Streamlit: Framework empleado para estructurar lógicamente los resultados en un panel de control interactivo (Dashboard), facilitando la segmentación visual de los objetivos demográficos y de consumo a través de pestañas dinámicas. Adicionalmente, se implementaron componentes de interfaz de usuario (Widgets), específicamente un control deslizante (Slider), que permite filtrar la base de datos en tiempo real según rangos de edad personalizados, garantizando una exploración analítica profunda y focalizada.

Análisis de Resultados

Este capítulo presenta los resultados obtenidos al aplicar las metodologías descritas en el capítulo anterior, enfocándose en el análisis estadístico descriptivo de las variables transaccionales y demográficas del año 2023 a través del panel interactivo.

5.1. Ventajas y Desventajas de los Tests Aplicados

Antes de detallar los hallazgos visuales, es metodológicamente pertinente evaluar el alcance de las herramientas estadísticas empleadas en este Análisis Exploratorio de Datos (EDA):

5.1.1. Matriz de Correlación:

- Ventajas: Permite identificar visual y numéricamente la fuerza y dirección de la relación lineal entre múltiples variables numéricas (por ejemplo, contrastar si la Edad afecta el Total Gastado).
- Desventajas: Mide únicamente asociación matemática, no causalidad. Adicionalmente, el test clásico de Pearson puede ser sensible a valores atípicos (outliers) que distorsionen el coeficiente.

5.1.2. Discretización Demográfica:


- Ventajas: Transformar la variable continua Edad en rangos categóricos facilita enormemente la interpretación visual y la detección de patrones macro en el comportamiento de consumo por generaciones.
- Desventajas: Al agrupar los datos se pierde la varianza interna y la granularidad de la variable original, asumiendo que un cliente de 26 años se comporta exactamente igual que uno de 35 por pertenecer al mismo segmento.

5.2. Estadística descriptiva por categoría

Tabla 5.1: Estadísticas descriptivas de consumo por categoría

Categoría	Transacciones	Edad_Promedio	Gasto_Promedio	Desv_Estandar	Ingreso_Total
Beauty	307	40.4	467.48	563.61	143515
Clothing	351	41.9	443.25	550.70	155580
Electronics	342	41.7	458.79	567.54	156905

Para comprender la composición demográfica de la base de clientes y determinar qué segmento representa la mayor fuerza compradora del negocio, se generó una pirámide poblacional a partir de los datos transaccionales. Como se observa en la siguiente figura, esta distribución visual permite contrastar claramente la participación de hombres y mujeres segmentados por sus respectivos rangos etarios durante el año 2023.




Al analizar la distribución de las transacciones, se hace evidente una reconfiguración del público objetivo. La mayor concentración de compras se agrupa sólidamente en el segmento de adultos de 46 a 55 años, con una participación equitativa entre hombres y mujeres (superando las 140 transacciones conjuntas). Por el contrario, se observa una marcada debilidad en la captación del segmento más joven (menores de 25 años), cuya participación es estadísticamente marginal. Esto sugiere que la oferta de valor de la tienda tiene alta resonancia en perfiles de mediana edad con poder adquisitivo consolidado.

5.3. Correlación de Variables Numéricas

Relación entre Edad y Monto Gastado. Para evaluar estadísticamente las dinámicas de compra y comprobar de manera empírica si el perfil demográfico determina el volumen de gasto, se procedió a generar un gráfico de dispersión bidimensional. Este método visual permite identificar si existe algún patrón de comportamiento, tendencia lineal o concentración de alto valor adquisitivo asociado a etapas de vida específicas, superando las limitaciones de la estadística descriptiva básica.


[1] -0.06056802



El gráfico de dispersión confirma de manera empírica y visual la ausencia de una correlación lineal significativa entre las variables. La formación de bandas horizontales a lo largo del eje Y responde a la naturaleza discreta de los precios y cantidades en el sector retail; sin embargo, lo destacable es que estas agrupaciones de gasto se mantienen constantes a lo largo de todo el eje X (Edad). Las compras de alto valor (superiores a los \$1,500) son ejecutadas indistintamente por clientes de 20 años como de 60 años. Esto demuestra que la edad no es un factor predictivo del nivel de gasto y valida la recomendación de aplicar estrategias de upselling de forma transversal a toda la clientela.

5.4. Evolución Temporal de los Ingresos (Serie de Tiempo Simple)


El seguimiento temporal de las ventas es un componente vital del análisis exploratorio, ya que permite observar el comportamiento y la evolución del flujo de caja a lo largo de los doce meses del año 2023. El análisis de esta serie de tiempo simple resulta estratégico para identificar de manera empírica en qué momentos del año ocurren los picos de demanda y las caídas críticas, información fundamental para la futura optimización de inventarios.



El análisis de la serie de tiempo simple, basado en el volumen de transacciones, revela una alta volatilidad en el flujo comercial durante el año 2023. En lugar de exhibir una tendencia estable, el comportamiento de compra fluctúa significativamente mes a mes. El pico máximo de actividad operativa se registró en mayo, superando la barrera de las 100 transacciones mensuales, seguido de repuntes importantes en el último trimestre (octubre y diciembre). Por el contrario, el mes de septiembre representó una contracción crítica en la afluencia, registrando el nivel más bajo del periodo (aproximadamente 65 transacciones). Este patrón irregular demuestra que el negocio opera bajo ciclos de demanda muy marcados, lo que exige estrategias ágiles: garantizar el máximo abastecimiento en mayo e implementar campañas agresivas para impulsar el tráfico de clientes durante la caída de septiembre.

5.5. Preferencias de Categorías por Edad

Finalmente, para trazar estrategias de marketing y abastecimiento mucho más precisas, es necesario cruzar la estructura demográfica con el comportamiento de compra específico. El siguiente gráfico ilustra cómo se distribuye la demanda de las distintas categorías de productos (como Ropa, Electrónica y Belleza) dentro de cada segmento de edad.



El cruce de variables demográficas y comerciales mediante barras apiladas revela gráficamente dónde se concentra el núcleo del negocio. Se confirma que el segmento de 46 a 55 años registra el mayor volumen total de transacciones, impulsado de manera significativa por una alta demanda en la categoría de Electrónica (bloque superior). Por otro lado, la categoría de Ropa mantiene una tracción sólida y constante, predominando fuertemente en los consumidores adultos a partir de los 36 años. Finalmente, los artículos de Belleza presentan un consumo base estable y transversal en todas las edades, sin llegar a dominar de forma absoluta ningún segmento. Estos resultados sugieren estratégicamente que las campañas publicitarias para productos tecnológicos deben abandonar el sesgo juvenil y focalizarse directamente en el público de mediana edad, quienes concentran el verdadero poder adquisitivo en esta categoría.

Conclusiones y Recomendaciones

A partir del Análisis Exploratorio de Datos (EDA) aplicado a los registros transaccionales del sector retail durante el año 2023, se derivan las siguientes conclusiones fundamentales:

1.- El análisis demostró empíricamente que la edad del consumidor no tiene un impacto predictivo sobre su nivel de gasto ($r = -0.06$), siendo los ingresos impulsados principalmente por la venta de artículos de alto valor unitario ($r = 0.85$).

Recomendación Fomentar el upselling. Se sugiere capacitar a la fuerza de ventas e implementar algoritmos de recomendación que incentiven la compra de productos Premium, maximizando el valor del ticket promedio.

2.- Existe una brecha generacional en la captación. Aunque el volumen demográfico principal se concentra en adultos jóvenes (26 a 35 años), el negocio no está logrando penetrar en la generación más joven (<25 años).

Recomendación Diseñar campañas de captación para la Generación más joven, utilizando estrategias de inbound marketing y programas de fidelización orientados específicamente a este segmento de mercado actualmente desaprovechado.

3.- Contrario a los supuestos tradicionales, el segmento entre 46 y 55 años resultó ser el motor transaccional más fuerte del año, impulsado abrumadoramente por la adquisición de productos de Electrónica.

Recomendación Redirigir y focalizar la pauta publicitaria de los artículos tecnológicos hacia los consumidores de 46 a 55 años, utilizando canales y mensajes acordes a su poder adquisitivo en lugar de enfocarse solo en el público juvenil.

4.- La rentabilidad del negocio presenta una alta vulnerabilidad estacional, con una dependencia crítica del mes pico (mayo) y una preocupante caída de ingresos en el tercer trimestre (septiembre).

Recomendación Implementar estrategias de inventario ágil, garantizando el máximo abastecimiento entre abril y mayo, y estructurar campañas de descuentos agresivos para septiembre con el fin de mitigar las caídas de demanda.

Apéndice A

Anexo A

Apéndice B

Anexo B

Apéndice C

Anexo C
